

Abordagem Híbrida de Inspeção: Avaliação da Eficácia de Grandes Modelos de Linguagem no Diagnóstico de Acessibilidade Web

Anonymous Author(s)

ABSTRACT

Evaluating web accessibility in systems with a large volume of screens is a costly and challenging process, demanding strategies that promote greater productivity without sacrificing quality. This work investigates the use of Large Language Models (LLMs) as a tool to support manual inspection, testing their ability to generate initial estimates of problems in interfaces that share common elements. To this end, an experimental evaluation was carried out in which an LLM analyzed a set of 5 new screens based on input from previously consolidated diagnoses of 25 other screens from the same ecosystem. The results demonstrate the scenarios in which the models were able to correctly identify accessibility barriers compared to 100% manual inspection, as well as the situations that induced hallucinations or inaccuracies. The findings help to position the role of LLMs in increasing productivity within web engineering processes focused on accessibility, highlighting the indispensable care required when integrating generative artificial intelligence into the workflow of specialists.

KEYWORDS

Acessibilidade Web, Grandes Modelos de Linguagem, Inspeção de Acessibilidade

1 INTRODUÇÃO

A evolução contínua da Web e a digitalização de serviços essenciais consolidaram a acessibilidade digital como um requisito indispensável para assegurar a inclusão de todos os cidadãos na sociedade contemporânea. Contudo, a garantia de conformidade com diretrizes internacionais, como as *Web Content Accessibility Guidelines* (WCAG) [11], e normas nacionais, como a ABNT NBR 17225 [1], impõe desafios práticos às equipes de desenvolvimento e auditoria. Em sistemas de grande escala ou ecossistemas institucionais complexos que possuem um elevado volume de telas, o processo de avaliação tradicional revela-se custoso, demorado e exaustivo, demandando estratégias inovadoras que promovam a produtividade sem comprometer a qualidade do diagnóstico.

Tradicionalmente, a comunidade de engenharia de software recorre a ferramentas automáticas de validação sintática (como WAVE e Axe) para acelerar a identificação de barreiras de acessibilidade. No entanto, essas ferramentas têm

limitações significativas na análise de critérios semânticos que requerem julgamento contextual humano. Diante disso, a recente proliferação de Grandes Modelos de Linguagem (LLMs), dotados de capacidade avançada de processamento de código e raciocínio contextual, motivou a exploração da inteligência artificial generativa como uma abordagem promissora para complementar ou aprimorar os métodos de inspeção existentes.

Pesquisas recentes têm buscado integrar LLMs à Engenharia Web voltada à acessibilidade sob diferentes perspectivas. Sistemas como o GenA11y, proposto por He et al. [4], e os scripts desenvolvidos por López-Gil [6], demonstraram que os modelos de linguagem conseguem realizar verificações semânticas e julgar violações além da simples correspondência de padrões sintáticos, superando avaliadores tradicionais. Adicionalmente, abordagens híbridas de remediação automática, como o AccessGuru de Hernández Castillo e Staab [5] e as arquiteturas integradas avaliadas por Paternò et al. [7], evidenciaram reduções expressivas em métricas de erros sintáticos e estruturais de código gerado. O uso de prompts de IA para avaliação da acessibilidade de páginas Web também foi reportado por França et al. [3], assim como a automação na geração de protótipos de telas para Android com requisitos de acessibilidade [13].

Apesar dos avanços descritos, a literatura científica identifica lacunas críticas que limitam a confiabilidade técnica desses modelos no cenário prático. Autores como Paternò et al. [7], Vera-Amaro e Rojano Caceres [10], e Vataavu [9] sublinham que erros semânticos persistentes, sensibilidade extrema à qualidade de estruturação dos prompts e o fenômeno de alucinações técnicas comprometem a aplicação autônoma de LLMs em inspeções de acessibilidade formais. Mais especificamente, ainda há uma escassez de estudos empíricos que avaliem o impacto incremental do nível de contexto normativo, de estratégias de teste procedimentais e do aprendizado em contexto (*in-context learning*) baseado em exemplos consolidados por especialistas humanos, especialmente sob a ótica de normas nacionais rigorosas, como a ABNT NBR 17225 [1].

Para preencher essa lacuna, este artigo propõe uma abordagem híbrida de inspeção baseada em engenharia de prompts incremental. O objetivo principal foi de investigar de que forma diferentes estratégias de interação e volumes de contexto afetam a eficácia de Grandes Modelos de Linguagem no suporte ao diagnóstico de acessibilidade Web. A equipe conduziu uma avaliação exploratória dividida em quatro cenários incrementais (Prompts 1, 2, 3 e 4), utilizando os modelos Google Gemini 3.1 Pro e GPT-5.5 High. A abordagem evolui desde um diagnóstico sem contexto normativo até um fluxo

complexo em múltiplos turnos (*multi-turn prompting*) alimentado por 25 relatórios de inspeções humanas anteriores como exemplos práticos. As análises em cinco novas telas de uma aplicação Web real demonstram os cenários de acerto, as causas de alucinações e os limites práticos da integração de IA ao fluxo de trabalho de especialistas.

As avaliações correspondem a inspeções de acessibilidade realizada por uma equipe de três especialistas de um projeto de desenvolvimento tecnológico realizado pela Universidade Federal de XYZ (omitido), em parceria com o órgão estadual ZYX do estado de ZZ. A partir da publicação da norma ABNT NBR 17225, o órgão concordou que a equipe da universidade alocasse uma equipe especializada para que os sistemas desenvolvidos no âmbito do acordo de cooperação entre o governo e a universidade tivessem conformidade com a norma.

A contribuição do trabalho consiste na identificação dos tipos de problemas que foram identificados com maior acurácia pelos modelos LLM, e quais problemas tinham maior incidência de problemas na identificação para diferentes tipos de prompts e entradas para treinamento.

O restante deste artigo está organizado da seguinte forma. A Seção 2 apresenta uma análise de trabalhos relacionados. Na Seção 3, são apresentados os aspectos relacionados à metodologia do trabalho. A Seção 4 apresenta resultados e discussão, e finalmente, a Seção 5 apresenta as conclusões e trabalhos futuros delineados.

2 TRABALHOS RELACIONADOS

A interseção entre inteligência artificial generativa e acessibilidade Web tem impulsionado diversas investigações focadas em mitigar o custo e a complexidade das avaliações de interfaces. A literatura recente divide-se, predominantemente, entre o uso de Grandes Modelos de Linguagem (LLMs) para a inspeção de barreiras semânticas e o desenvolvimento de abordagens voltadas à correção automatizada de código inacessível.

No cenário da detecção e inspeção, diferentes pesquisas exploram a capacidade de raciocínio contextual dos LLMs para avaliar critérios semânticos, superando as limitações de ferramentas baseadas em regras rígidas. He et al. [4] introduziram o sistema *GenA11y*, demonstrando que os modelos conseguem atuar além da simples correspondência de padrões sintáticos, identificando nuances de acessibilidade que tradicionalmente exigiriam inspeção humana. De forma complementar, López-Gil [6] avaliou o uso de scripts apoiados por LLMs, evidenciando avanços significativos no julgamento de violações complexas de código local. Por outro lado, a literatura faz ressalvas críticas quanto à confiabilidade técnica dessas abordagens. Autores como Vera-Amaro e Rojano Caceres [10] e Vatavu [9] sublinham que esses modelos permanecem altamente sensíveis à estruturação e engenharia dos *prompts*. Além disso, esses estudos apontam a persistência de erros semânticos sutis e o risco latente de alucinações técnicas, o que impede que os LLMs substituam por completo os

avaliadores humanos em inspeções formais de conformidade com padrões de acessibilidade Web.

Uma segunda vertente foca não apenas no diagnóstico, mas na correção automática de interfaces. Nesse contexto, Hernández Castillo e Staab [5] propuseram o *AccessGuru*, um sistema baseado em IA focado na remediação de código que demonstrou reduções expressivas em métricas de erros sintáticos. No mesmo sentido, Paternò et al. [7] exploraram arquiteturas integradas capazes de reescrever trechos de código Web para se adequarem às diretrizes internacionais. Contudo, os autores observaram que, embora a estrutura sintática gerada seja frequentemente correta, o modelo muitas vezes falha em preservar a intenção semântica original da interface, o que reforça a dependência contínua de validação humana exaustiva.

Diante do panorama delineado pela literatura, observa-se uma lacuna clara sobre como contornar sistematicamente as alucinações e os erros semânticos dos LLMs durante o processo de inspeção, uma vez que a maioria dos trabalhos foca na capacidade isolada dos modelos ou na correção direta de trechos de código. Este trabalho avança em relação ao estado da arte ao propor e avaliar uma estratégia de engenharia de prompts incremental e em múltiplos turnos (*multi-turn prompting*). Em vez de contar com prompts estáticos ou puramente normativos, nossa abordagem introduz o aprendizado em contexto (*in-context learning*) baseado na experiência humana real, alimentando os modelos com dados de 25 relatórios de inspeções anteriores. Com isso, investigamos empiricamente os limites práticos e as melhorias de assertividade obtidas à medida que o nível de contexto fornecido ao modelo evolui, estabelecendo uma metodologia para mitigar as principais limitações apontadas pela literatura atual.

3 METODOLOGIA

Este estudo foi conduzido como uma avaliação exploratória, com o objetivo de comparar diferentes estratégias de interação com Grandes Modelos de Linguagem, do inglês Large Language Models (LLM), no apoio à inspeção de acessibilidade Web. Para isso, foram definidos quatro cenários de teste baseados em prompts, variando progressivamente o nível de contexto fornecido ao modelo, a presença de documentos normativos, o uso de procedimentos externos de avaliação e a incorporação de exemplos prévios de inspeções manuais.

A avaliação proposta neste trabalho foi conduzida por meio da elaboração de prompts estruturados para interação com uma LLM. A construção desses prompts fundamentou-se nos princípios da engenharia de prompts, entendida como a prática de formular instruções em linguagem natural capazes de orientar modelos pré-treinados na execução de tarefas específicas, sem modificar seus parâmetros internos. Segundo Sahoo [8], os prompts constituem instruções específicas de tarefa que ampliam a eficácia dos modelos ao fornecer contexto e direcionamento para a geração das respostas. De forma semelhante, Cain [2] destaca que prompts bem elaborados atuam como um mecanismo de direcionamento, permitindo

que os usuários obtenham resultados mais consistentes e alinhados aos seus objetivos.

Para a definição da estratégia de interação com a LLM, este estudo adotou como referência o catálogo de padrões de engenharia de prompts proposto por White [12]. Os autores apresentam um conjunto de padrões reutilizáveis que podem ser combinados para estruturar instruções mais robustas e reduzir ambiguidades durante a execução de tarefas complexas.

A elaboração dos prompts teve como objetivo reduzir ambiguidades, padronizar as respostas e tornar o procedimento de avaliação mais controlado. Neste estudo, o *Persona Pattern* foi utilizado para atribuir ao modelo o papel de avaliador de acessibilidade Web; o *Template Pattern* definiu a estrutura esperada dos relatórios de saída, especialmente no formato CSV; e o *Workflow Pattern* organizou a sequência de etapas de análise, incluindo leitura do material de entrada, identificação dos critérios aplicáveis, inspeção do código HTML e geração do diagnóstico. Além disso, foram incorporadas instruções inspiradas nos padrões *Fact-Check List* e *Reflection*, com o objetivo de incentivar o modelo a justificar suas classificações com base nas evidências disponíveis e a evitar inferências não sustentadas pelo material fornecido.

Com base nesses princípios, foram elaborados diferentes prompts de teste para avaliar a capacidade da LLM em apoiar o processo de inspeção de acessibilidade na Web. Os prompts foram concebidos de forma incremental, variando o volume de contexto fornecido ao modelo e o nível de detalhamento das instruções, permitindo analisar a influência dessas características sobre a qualidade dos diagnósticos gerados.

Os Prompts 1, 2 e 3 foram executados com o modelo Google Gemini 3.1 Pro, com nível de raciocínio padrão, disponibilizado por meio do programa *Google for Education* e acessado em junho de 2026. A escolha foi motivada pela disponibilidade de acesso institucional e pela capacidade do modelo de processar os arquivos HTML (*HyperText Markup Language*), documentos em *Markdown* e planilhas CSV empregados na avaliação. As interações foram realizadas no site do próprio serviço¹, sem configurações adicionais além da seleção do modelo e do nível de raciocínio. Cada um desses três testes foi conduzido em uma nova interação.

O Prompt 4 também seria executado no Gemini, mas as tentativas não produziram uma saída compatível com o procedimento de teste. Na primeira tentativa, a execução da tarefa foi interrompida por uma mensagem de erro, possivelmente devido a restrições de capacidade ou recusa do sistema. Quando solicitado a refazer a resposta, produziu uma avaliação baseada em requisitos da WCAG, em desacordo com a instrução de utilizar a ABNT NBR 17225 como fonte normativa. Diante da impossibilidade de obter o relatório solicitado, esse teste foi executado com o GPT-5.5 High. Para preservar a comparabilidade do procedimento, foram mantidos o mesmo prompt, os mesmos arquivos de entrada, a divisão dos exemplos em lotes de até dez anexos, a sequência de turnos e os critérios de geração e validação dos relatórios. No Prompt

4, o histórico da conversa foi preservado para permitir o uso dos exemplos fornecidos como contexto. Todos os prompts, arquivos de entrada e relatórios produzidos foram registrados para posterior comparação com as avaliações manuais de referência.

Como conjunto de avaliação, foram selecionadas cinco telas de uma aplicação Web, previamente avaliadas manualmente segundo os critérios da ABNT NBR 17225 [1]. Essas avaliações manuais foram adotadas como referência para comparação dos diagnósticos produzidos pela LLM. O desenho do estudo foi organizado em duas etapas. Na primeira etapa, de caráter exploratório, os Prompts 1, 2 e 3 foram aplicados individualmente a uma tela distinta, com o objetivo de analisar o efeito de diferentes níveis de contexto normativo e procedimental sobre a qualidade dos diagnósticos. Na segunda etapa, o Prompt 4 foi aplicado às cinco telas selecionadas, utilizando avaliações manuais anteriores como exemplos de apoio ao aprendizado em contexto. Essa organização permitiu investigar, inicialmente, o comportamento do modelo sob diferentes configurações de prompt e, em seguida, avaliar de forma mais abrangente a estratégia baseada em exemplos humanos.

As cinco páginas utilizadas como exemplos correspondiam a funcionalidades distintas do sistema XYA (omitido para avaliação), contemplando tanto telas de cadastro quanto de consulta. Em conjunto, essas interfaces apresentavam formulários, tabelas, menus de navegação, botões de ação, componentes expansíveis e outros elementos interativos característicos de aplicações Web administrativas. As avaliações manuais apresentavam distribuição semelhante entre as cinco páginas, variando entre 67 e 86 conformidades, 23 e 36 não conformidades e 33 a 43 itens não aplicáveis, evidenciando um conjunto representativo de critérios atendidos e de problemas de acessibilidade segundo a ABNT NBR 17225. Entre as não conformidades observadas com maior frequência destacavam-se problemas relacionados ao uso de elementos nativos, gerenciamento de sessões (tempo de inatividade e reautenticação), contraste de texto, visibilidade do indicador de foco, acessibilidade por teclado e identificação do propósito de botões. Dessa forma, o conjunto de exemplos contemplava tanto requisitos estruturais quanto aspectos relacionados à interação e à usabilidade da interface, fornecendo ao modelo exemplos diversificados de conformidade e não conformidade para aplicação de aprendizado em contexto (*in-context learning*).

Devido à diferença no número de telas avaliadas em cada etapa, as comparações entre os Prompts 1, 2 e 3 e o Prompt 4 devem ser interpretadas como evidências exploratórias, e não como uma comparação estatística controlada entre condições equivalentes.

3.1 Prompt 01 — Sem contexto normativo

O primeiro teste consistiu na elaboração de um prompt para avaliar a capacidade do Google Gemini de realizar uma inspeção de acessibilidade sem o fornecimento prévio do conteúdo da ABNT NBR 17225 [1]. O modelo recebeu apenas a instrução para avaliar uma página HTML conforme a norma,

¹Gemini: Gemini

sendo orientado a pesquisar, identificar e sintetizar os critérios disponíveis antes de iniciar a inspeção.

Após essa etapa, o Google Gemini deveria analisar o código HTML, verificar cada critério identificado e classificá-lo como *Conformidade*, *Não Conformidade* ou *Não aplicável*, registrando as evidências encontradas durante a avaliação.

Embora o conteúdo da norma não fosse disponibilizado, foi fornecida uma planilha modelo para padronizar a saída dos resultados. O relatório gerado deveria seguir essa estrutura, contendo os campos **Item**, **Descrição**, **Situação** e **Observações**, permitindo a comparação entre os diferentes experimentos realizados.

3.2 Prompt 02 — Com contexto da norma ABNT

No segundo teste, além do código HTML da página, foi fornecido ao Google Gemini um arquivo contendo a checklist da ABNT NBR 17225 [1], o qual reúne os critérios utilizados na avaliação de acessibilidade. Diferentemente do primeiro teste, o modelo não precisou recuperar informações sobre a norma, devendo utilizar exclusivamente o conteúdo disponibilizado no arquivo.

O prompt instruiu o Google Gemini a identificar os critérios presentes na checklist, inspecionar o código HTML e avaliar cada item como *Conformidade*, *Não Conformidade* ou *Não aplicável*, fundamentando todas as justificativas nas informações fornecidas. Também foi explicitamente solicitado que o modelo não realizasse buscas externas nem inferisse requisitos que não estivessem presentes no documento.

Assim como no primeiro teste, a saída deveria ser gerada em uma planilha seguindo um modelo predefinido, contendo os campos *Item*, *Descrição*, *Situação* e *Observações*, de forma a padronizar os resultados para posterior comparação.

3.3 Prompt 03 — ABNT e estratégias da WCAG

O terceiro teste manteve a estrutura do Prompt 2, utilizando como referência a checklist da ABNT NBR 17225 [1]. Entretanto, foi acrescentada uma etapa de construção de estratégias de teste fundamentadas na documentação oficial da WCAG 2.2, que contém técnicas associadas aos critérios de sucesso que listam procedimentos de teste explícito para cada técnica.

Para cada item da norma ABNT NBR 17225, o modelo deveria identificar os critérios de sucesso correspondentes na WCAG 2.2 [11], consultar suas técnicas de implementação, priorizando as *Sufficient Techniques*, e utilizar os procedimentos de teste documentados para elaborar um plano de avaliação reproduzível. Essas estratégias deveriam ser aplicadas na inspeção do código HTML antes da geração do relatório final.

Além do arquivo contendo os resultados da avaliação, o Google Gemini também deveria produzir um documento descrevendo, para cada item da ABNT, os critérios da WCAG utilizados, as técnicas consultadas, os procedimentos de teste identificados e a estratégia consolidada de avaliação. O objetivo dessa abordagem foi investigar se a utilização conjunta da ABNT NBR 17225 e dos procedimentos de teste da WCAG

2.2 poderia produzir avaliações mais consistentes e justificadas.

3.4 Prompt 04 — Exemplos gerados por humanos e norma ABNT

O quarto teste adotou uma abordagem baseada em interação em múltiplos turnos (*multi-turn prompting*). O protocolo, originalmente estruturado para contornar o limite de dez anexos por mensagem da plataforma utilizada, foi mantido na execução com o GPT-5.5 High. Diferentemente dos testes anteriores, o contexto foi construído ao longo de quatro interações antes do início das avaliações.

Nos três primeiros turnos, foram fornecidas as 25 planilhas com resultados de avaliações manuais previamente realizadas no projeto XYZ, distribuídas em três lotes (10, 10 e 5 arquivos), para que o modelo assimilasse o padrão metodológico empregado na identificação, classificação e descrição dos problemas de acessibilidade, sem realizar novas avaliações. No quarto turno, foi disponibilizada os itens da checklist da ABNT NBR 17225 [1], permitindo relacionar os exemplos aos respectivos critérios normativos.

Após essa etapa de contextualização, o GPT-5.5 High recebeu o código HTML de cada uma das cinco telas, avaliadas sequencialmente na mesma conversa. O modelo foi instruído a utilizar os exemplos apenas como referência para interpretação dos critérios e padronização dos diagnósticos, gerando ao final de cada turno um relatório em formato CSV, conforme a estrutura adotada em toda a pesquisa.

3.5 Comparação entre Prompts

A estratégia do estudo foi estruturada de forma incremental, aumentando progressivamente o nível de contexto disponibilizado em cada experimento. Enquanto o Prompt 1 avaliou a capacidade do Gemini de realizar inspeções utilizando apenas seu conhecimento prévio, os Prompts 2 e 3 introduziram, respectivamente, os critérios da ABNT NBR 17225 [1] e o suporte aos procedimentos de teste da WCAG 2.2 [11]. Por fim, o Prompt 4, executado com o GPT-5.5 High, incorporou exemplos reais de avaliações manuais por meio de uma abordagem de aprendizado em contexto (*in-context learning*), permitindo investigar o impacto do conhecimento acumulado sobre a qualidade das avaliações produzidas.

A Tabela 1 apresenta uma síntese das principais características dos quatro prompts empregados, destacando as diferenças quanto ao contexto fornecido ao modelo, à estratégia de interação adotada e às hipóteses investigadas em cada experimento.

4 RESULTADOS E DISCUSSÃO

Os resultados obtidos foram analisados por meio da comparação entre as avaliações produzidas pelas LLMs e as avaliações manuais realizadas por especialistas em acessibilidade, utilizadas como referência neste estudo. A análise considerou as diferenças quanto ao volume de contexto fornecido, à estratégia de engenharia de prompts empregada e ao uso de informações normativas e exemplos prévios de avaliações.

Table 1: Comparação entre os prompts utilizados nos experimentos.

Característica	Prompt 1	Prompt 2	Prompt 3	Prompt 4
Objetivo	Avaliação sem contexto	Avaliação com norma ABNT	Norma ABNT + Conteúdo da WCAG	Avaliação baseada em exemplos humanos + Avaliação com norma ABNT
Nº de turnos	1	1	1	4 turnos de contextualização + 5 turnos de avaliação
Contexto fornecido	HTML	HTML + checklist da norma ABNT	HTML + checklist da norma ABNT + Link para consulta a WCAG	25 avaliações manuais + checklist da norma ABNT + HTML
Pesquisa externa	Sim	Não	Apenas WCAG	Não
Base normativa	Conhecimento do modelo	Checklist da norma ABNT	Checklist da norma ABNT + técnicas WCAG	Checklist da norma ABNT
Aprendizado em contexto	Não	Não	Não	Sim (25 avaliações humanas)
Forma de avaliação	Página única	Página única	Página única	Cinco páginas, avaliadas uma por vez.
Estrutura da resposta	CSV	CSV	Markdown + CSV	CSV
Hipótese	Falta de contexto prévio pode gerar alucinação	Critérios explícitos podem ajudar na eficácia da avaliação	Solicitação de pesquisa além do contexto fornecido pode gerar alucinação	Uso de exemplos humanos melhora a capacidade de diagnóstico

Para cada teste, foram examinadas a capacidade do modelo em identificar corretamente problemas de acessibilidade, a consistência das justificativas apresentadas, a aderência aos critérios da ABNT NBR 17225 [1] e a ocorrência de imprecisões ou alucinações. Além da comparação quantitativa entre os resultados obtidos, são discutidos os impactos das diferentes estratégias de contextualização no desempenho do modelo, buscando identificar em quais cenários o uso de LLMs pode contribuir de forma mais efetiva como ferramenta de apoio à inspeção de acessibilidade Web.

4.1 Execução do Prompt 01 — Sem contexto normativo

Conforme ilustrado na Figura 1, o resultado da avaliação demonstra que o uso do Gemini para o diagnóstico automatizado é inviável para certificações e inspações formais baseadas na ABNT NBR 17225 [1]. A principal limitação observada foi a baixíssima granularidade e cobertura da norma, uma vez que o modelo condensou a complexidade de dezenas de requisitos rigorosos em apenas 16 macroitens genéricos no relatório gerado.

Em termos quantitativos, a avaliação manual contemplou integralmente os 146 itens da checklist da ABNT NBR 17225, identificando 81 Conformidades, 13 Não Conformidades e 52 itens Não Aplicáveis. Em contraste, o Gemini avaliou apenas 16 itens, classificando 10 como *Conformidade*, 1 como *Não Conformidade* e 5 como *Não aplicável*. Esse resultado corresponde a uma cobertura aproximada de 11,0% dos requisitos considerados na avaliação manual, deixando de analisar cerca de 89,0% dos itens previstos pela norma. Embora a




Figure 1: Comparação do resultado e da cobertura de itens da norma ABNT NBR 17225 pelo Prompt 1, executado pelo Gemini em relação à avaliação manual.

proporção de Conformidades identificadas pelo modelo seja elevada, esse percentual deve ser interpretado com cautela,

uma vez que decorre da reduzida quantidade de critérios efetivamente avaliados e não necessariamente reflete um maior nível de conformidade da interface.

Os resultados sugerem que, na ausência do conteúdo normativo como contexto explícito, o modelo limita sua análise a um conjunto reduzido de verificações de acessibilidade amplamente difundidas em seu treinamento, sem realizar uma inspeção sistemática dos requisitos específicos estabelecidos pela ABNT NBR 17225. Consequentemente, o diagnóstico produzido apresenta cobertura insuficiente para representar de forma abrangente o nível de conformidade da aplicação em relação à norma.

Além da limitação de cobertura, observa-se uma restrição inerente à arquitetura do modelo. A avaliação é realizada exclusivamente sobre o código-fonte estático da página, sem a execução da interface em ambiente de navegador. Dessa forma, o modelo não é capaz de avaliar aspectos dependentes da renderização da aplicação, como a navegação por teclado, alterações dinâmicas da interface, cálculo efetivo do contraste entre elementos renderizados ou a verificação do comportamento funcional exigido por diversos requisitos da ABNT NBR 17225 [1].

Como consequência dessas limitações, o modelo tende a produzir diagnósticos suscetíveis à ocorrência de falsos negativos. Em diversos casos, a presença de elementos sintáticos, como atributos HTML ou textos alternativos, é interpretada como evidência suficiente de conformidade, sem que sejam verificados aspectos relacionados à adequação semântica, ao contexto de uso ou à efetiva experiência do usuário. Essa abordagem pode levar à superestimação do nível de acessibilidade da interface, comprometendo a confiabilidade dos resultados para fins de auditoria, certificação ou avaliação formal de conformidade com a norma.

4.2 Execução do Prompt 02 — Com contexto da ABNT

Os resultados obtidos no Prompt 2 evidenciaram o impacto do fornecimento explícito do conteúdo normativo ao modelo. Ao receber a checklist da ABNT NBR 17225 [1] juntamente com o código HTML da tela avaliada, o Google Gemini passou a produzir diagnósticos diretamente rastreáveis aos critérios da norma, eliminando a necessidade de recuperação de informações a partir de seu conhecimento prévio.

Em termos de cobertura, conforme exibido na Figura 2, a avaliação manual contemplou integralmente os 146 itens da checklist da ABNT NBR 17225, identificando 84 Conformidades, 24 Não Conformidades e 38 itens Não Aplicáveis. Em contraste, o modelo avaliou 12 requisitos da norma, classificando 10 como *Conformidade*, 1 como *Não Conformidade* e 1 como *Não aplicável*. A única não Conformidade identificada correspondeu ao Requisito referente à ausência de mecanismo de *skip link* para ignorar blocos de conteúdo repetidos. As justificativas apresentadas pelo modelo foram consistentes com o texto normativo fornecido, referenciando corretamente elementos estruturais da página, como o uso

de `aria-label`, atributos `alt` em imagens e a declaração de idioma via `lang="pt-br"`.




Figure 2: Comparação do resultado e da cobertura de itens da norma ABNT NBR 17225 pelo Prompt 2, executado pelo Gemini em relação à avaliação manual.

Contudo, apesar da maior rastreabilidade dos diagnósticos em comparação ao Prompt 1, o teste evidenciou uma limitação relevante de cobertura. A avaliação manual de referência contemplou 146 itens da ABNT NBR 17225, ao passo que o modelo avaliou apenas 12, representando aproximadamente 8,2% do total de requisitos previstos pela norma. Essa discrepância indica que, embora o modelo tenha sido capaz de produzir avaliações tecnicamente coerentes para os itens que identificou, não percorreu de forma exaustiva o conjunto de critérios disponibilizados na checklist.

Esse comportamento sugere que o modelo tende a priorizar os critérios mais frequentemente associados a avaliações de acessibilidade em seu treinamento, mesmo quando instruído a basear-se exclusivamente no documento fornecido. A elevada proporção de Conformidades, portanto, não reflete necessariamente um nível superior de acessibilidade da interface, mas sim a cobertura parcial dos requisitos analisados. Dessa forma, embora o Prompt 2 tenha produzido diagnósticos mais fundamentados e rastreáveis do que o teste anterior, os resultados indicam que o fornecimento do conteúdo normativo isoladamente não é suficiente para garantir a completude da inspeção, sendo necessárias estratégias adicionais para assegurar a avaliação integral dos critérios da norma.

4.3 Execução do Prompt 03 — ABNT e estratégias da WCAG

A aplicação do Prompt 3 evidenciou limitações na execução completa do fluxo de avaliação proposto. Conforme apresentado na Figura 3, a avaliação manual contemplou os 146 itens da checklist da ABNT NBR 17225, identificando 85 Conformidades, 23 Não Conformidades e 38 itens Não Aplicáveis. Em contraste, o modelo avaliou apenas 17 requisitos, classificando 14 como Conformidade, 0 como Não Conformidade e 4 como Não Aplicáveis, correspondendo a aproximadamente 11,6% dos itens considerados na avaliação manual.




Figure 3: Comparação do resultado e da cobertura de itens da norma ABNT NBR 17225 pelo Prompt 3, executado pelo Gemini em relação à avaliação manual.

A análise do documento *Markdown* gerado apresentou comportamento semelhante. Embora o prompt determinasse a elaboração de estratégias de teste para todos os requisitos da ABNT NBR 17225 [1], o artefato produzido contemplou apenas uma parcela reduzida dos critérios previstos. Para os requisitos efetivamente documentados, entretanto, as estratégias mostraram-se tecnicamente consistentes, estabelecendo corretamente a correspondência entre os critérios de sucesso da WCAG 2.2 e os respectivos requisitos da ABNT, além de empregar procedimentos de teste compatíveis com a documentação oficial.

Os resultados indicam que a principal limitação do Prompt 3 esteve relacionada à baixa cobertura dos requisitos da norma, restringindo a avaliação aos critérios previamente documentados. Dessa forma, embora o modelo tenha produzido estratégias tecnicamente coerentes para os itens analisados, sua execução não foi suficiente para realizar uma avaliação

abrangente da Conformidade da página em relação à ABNT NBR 17225.

4.4 Execução do Prompt 04 — Exemplos humanos e ABNT

A execução do Prompt 4 gerou relatórios completos para as cinco telas, contemplando a totalidade dos 146 itens da ABNT NBR 17225, o que superou a cobertura parcial dos testes anteriores. Como ilustra a Figura 4, a distribuição agregada das classificações do GPT-5.5 High aproximou-se da avaliação humana, embora o modelo tenha registrado um número maior de Não Conformidades.

Apesar da completude formal dos relatórios, a concordância exata item a item foi de aproximadamente 70%, com variações moderadas entre as telas. Esse índice demonstra que preencher todos os requisitos da norma não equivale a reproduzir o julgamento exato dos especialistas, evidenciando a distinção entre a geração completa do documento e a precisão das classificações atribuídas.

Embora a distribuição agregada do GPT-5.5 High seja próxima à da avaliação manual, essa proximidade não representa equivalência entre os diagnósticos. Houve divergências nos dois sentidos: o modelo classificou como não conformes requisitos considerados conformes pelos avaliadores e também deixou de reconhecer parte das não conformidades manuais. Assim, os totais gerais descrevem um comportamento semelhante entre as avaliações, mas ocultam diferenças relevantes quando cada requisito é examinado individualmente.

Os exemplos manuais fornecidos como contexto parecem ter contribuído para a padronização da estrutura e do nível de detalhamento das justificativas. Contudo, esse efeito não pode ser isolado, pois o Prompt 4 foi executado com outro modelo e em um conjunto maior de telas. A tentativa malsucedida de aplicar o mesmo protocolo no Gemini reforça a relevância operacional da troca de modelo, mas impede de atribuir a melhora exclusivamente ao aprendizado em contexto. Os resultados sustentam, portanto, a eficácia do procedimento para controlar a cobertura e organizar a saída, sem estabelecer uma relação causal com um único componente do prompt.

4.5 Análise transversal dos prompts

Considerados em conjunto, os quatro testes mostram que fundamentação, cobertura e concordância são dimensões distintas do desempenho das LLMs. O fornecimento da norma tornou os diagnósticos mais rastreáveis, mas não ampliou a cobertura nos Prompts 2 e 3. No Prompt 4, a combinação de exemplos humanos, dos itens da checklist e instruções explícitas eliminou as omissões, sem eliminar as divergências de classificação. Desse modo, o aumento de contexto contribuiu para controlar a forma e a abrangência da saída, mas não substituiu as evidências obtidas pela interação direta com a interface.

Esse comportamento é compatível com os resultados de Vera-Amaro e Rojano Caceres, que identificaram melhora na acessibilidade quando os modelos receberam prompts especificamente orientados à tarefa [10]. Ao mesmo tempo, a




Figure 4: Comparação agregada dos resultados e da cobertura dos itens da ABNT NBR 17225 nas cinco telas avaliadas pelo Prompt 4, executado com o GPT-5.5 High, em relação às avaliações manuais.

permanência de divergências semânticas e comportamentais aproxima-se das limitações relatadas por Paternò et al., cujas remediações ainda apresentaram erros estruturais e compreensão incompleta da intenção da página [7]. No presente estudo, essa limitação torna-se particularmente visível nos requisitos que dependem de foco, teclado, conteúdo dinâmico ou interpretação contextual, pois o código estático não oferece evidência suficiente para reproduzir integralmente a inspeção humana.

Os resultados também convergem com Hernández Castillo e Staab e com Vatavu quanto à necessidade de supervisão humana nas decisões finais, sobretudo diante de ambiguidades semânticas [5, 9]. Embora López-Gil tenha obtido elevada detecção de problemas em verificações tradicionalmente manuais, o próprio estudo restringe a generalização a sites e critérios específicos [6]. Essa diferença de escopo reforça que taxas de desempenho não devem ser comparadas isoladamente entre trabalhos: neste estudo, os 146 itens da checklist da ABNT NBR 17225 e a inclusão de requisitos dependentes de comportamento impõem uma tarefa mais ampla do que a verificação de conjuntos selecionados de critérios.

Portanto, o padrão observado nos quatro prompts posiciona as LLMs como instrumentos de apoio, capazes de organizar verificações, relacionar evidências ao texto normativo e reduzir omissões quando recebem instruções suficientemente restritivas. Sua contribuição mais consistente está na estruturação e na triagem do processo de inspeção; a validação

especializada continua necessária para confirmar o comportamento, resolver ambiguidades e evitar que justificativas plausíveis sejam confundidas com evidências de conformidade.

5 CONCLUSÃO E TRABALHOS FUTUROS

Este trabalho apresentou uma investigação sobre o uso de Grandes Modelos de Linguagem (LLMs) como ferramentas de apoio à avaliação de acessibilidade Web baseada na ABNT NBR 17225. Por meio da comparação entre diferentes estratégias de engenharia de prompts e avaliações realizadas por especialistas, foi possível identificar fatores que influenciam diretamente a qualidade, a cobertura e a confiabilidade dos diagnósticos produzidos pelos modelos.

Os experimentos mostraram que a estrutura do prompt desempenha papel decisivo na execução da tarefa. Estratégias que apenas ampliam o contexto disponível ao modelo não garantem avaliações completas, enquanto abordagens que impõem uma estrutura sistemática de inspeção conseguem aumentar significativamente a cobertura dos requisitos. Entretanto, mesmo nos cenários de melhor desempenho, permaneceram divergências em relação às avaliações humanas, evidenciando que a cobertura dos critérios não é suficiente para assegurar a precisão dos diagnósticos.

Os resultados obtidos reforçam que as LLMs representam uma tecnologia promissora para apoiar especialistas na condução de inspeções de acessibilidade, reduzindo esforço operacional, padronizando relatórios e acelerando etapas da avaliação. Contudo, as limitações observadas indicam que esses modelos ainda não oferecem o nível de confiabilidade necessário para substituir avaliações humanas em processos de auditoria ou certificação.

Como trabalhos futuros, pretende-se investigar a integração de LLMs com técnicas de *Retrieval-Augmented Generation* (RAG), arquiteturas baseadas em agentes e outros modelos de linguagem, buscando ampliar simultaneamente a cobertura dos requisitos e a precisão das avaliações. Também pretende-se realizar análises sobre o uso de LLMs como apoio nas avaliações de páginas Web após a correção efetuada pós-avaliação, para análise e verificação do volume de trabalho que é de fato apoiado por essas ferramentas no longo prazo.

AGRADECIMENTOS

Agradecemos ao projeto XYY (omitido) pelo financiamento ao projeto. Declaramos que a ferramenta Gemini foi utilizada para apoio na revisão do texto. Os autores têm responsabilidade intelectual por todo o texto redigido.

REFERENCES

- [1] ABNT. 2024. *ABNT NBR 17225: Acessibilidade em sistemas de informação e comunicação*. Technical Report. Associação Brasileira de Normas Técnicas, Rio de Janeiro.
- [2] William Cain. 2024. Prompting Change: Exploring Prompt Engineering in Large Language Model AI and Its Potential to Transform Education. *TechTrends* 68, 1 (1 2024), 47–57. doi:10.1007/s11528-023-00896-0
- [3] Lúcio Cauper Freitas de França, Lisieux Marie M dos S Andrade, and Windson Viana de Carvalho. 2025. Um Estudo Sobre o Uso de Prompts LLM para a Avaliação da Acessibilidade Web dos

- Portais das Prefeituras da Região dos Sertões dos Crateús. In *Brazilian Symposium on Multimedia and the Web (WebMedia)*. SBC, 580–584.
- [4] Ziyao He, Syed Fatiul Huq, and Sam Malek. 2025. Enhancing Web Accessibility: Automated Detection of Issues with Generative AI. *Proceedings of the ACM on Software Engineering* (2025). doi:10.1145/3729371
- [5] Francisco Daniel Hernández Castillo and Steffen Staab. 2025. AccessGuru: Leveraging LLMs to Detect and Correct Web Accessibility Violations in HTML Code. doi:10.48550/arxiv.2507.19549 arXiv preprint.
- [6] Juan-Miguel López-Gil. 2024. Turning manual web accessibility success criteria into automatic: an LLM-based approach. *Universal Access in the Information Society* (2024). doi:10.1007/s10209-024-01108-z
- [7] Fabio Paternò, Manuela Vinci, and Marco Manca. 2025. How an LLM Can Improve Automatic Web Accessibility Validation?. In *Proceedings of the ACM*. doi:10.1145/3750069.3750310
- [8] Pranab Sahoo, Ayush Kumar Singh, Sriparna Saha, Vinija Jain, Samrat Mondal, and Aman Chadha. 2024. A Systematic Survey of Prompt Engineering in Large Language Models: Techniques and Applications. arXiv:2402.07927 [cs.AI]
- [9] Radu-Daniel Vatavu. 2025. When LLM-Generated Code Perpetuates User Interface Accessibility Barriers, How Can We Break the Cycle?. In *Proceedings of the ACM*. doi:10.1145/3744257.3744266
- [10] Guillermo Vera-Amaro and Jose Rafael Rojano Caceres. 2025. Accessible Web Content Generation Using LLMs: An Empirical Study on Prompting Strategies and Template-Guided Remediation. *IEEE Latin America Transactions* (2025). doi:10.1109/tla.2025.11231224
- [11] W3C. 2023. *Web Content Accessibility Guidelines (WCAG) 2.2*. Technical Report. World Wide Web Consortium. <https://www.w3.org/TR/WCAG22/>
- [12] Jules White, Quchen Fu, Sam Hays, Michael Sandborn, Carlos Olea, Henry Gilbert, Ashraf Elnashar, Jesse Spencer-Smith, and Douglas C. Schmidt. 2023. A Prompt Pattern Catalog to Enhance Prompt Engineering with ChatGPT. doi:10.48550/arXiv.2302.11382 arXiv preprint.
- [13] Lucas Emanuel Oliveira Xavier, Daniel Mesquita Feijó Rabelo, Ribamar de Souza Martins, and Windson Viana. 2025. Image-to-UI Accessibility: Assessing ChatGPT's Effectiveness in Generating Accessible Android Screens from Figma Templates. In *Brazilian Symposium on Multimedia and the Web (WebMedia)*. SBC, 302–311.